
FINAL PROJECT

Hotel Booking Cancellation Specialist

Binary Classification - Hotel Reservation Cancellation

Nama : Maulana Abdul Aziz

NPM : 50425612

Kelas : IIA04

1. Data Understanding

1.1 Import Library

Tujuan

- Mengimpor library yang akan digunakan

```
# Analisis Data
import pandas as pd
import numpy as np

# Visualisasi
import matplotlib.pyplot as plt
import seaborn as sns

# Interpretasi
# - Mengimpor library analisis data (pandas, numpy)
# - Membuat visualisasi (matplotlib, seaborn)
# - Kedepannya akan ada import modul tertentu kembali (matplotlib & seaborn
    yang lebih spesifik, lalu module machine learning), bukan pada cell
    ini namun pada cell terkait
```

1.2 Load Dataset

Tujuan

- Memuat dataset hotel booking cancellation dari sumber resmi dataset.

```
url = "https://raw.githubusercontent.com/rfordatascience/tidytuesday/master/data/2020/2020-02-11/hotels.csv"
df = pd.read_csv(url)

# Interpretasi
# - Dataset diambil langsung ke sumber online menggunakan URL
# - Fungsi df sebagai pembaca dataset dari sumber
```

1.3 Dataset Overview

Tujuan

- Melihat & memahami ukuran data, struktur data secara umum
- Mengidentifikasi tipe data dan ringkasan statistik
- Berkenalan dengan dataset secara keseluruhan

```
# Dataset overview
df.head()

# Interpretasi
# - Setiap baris merepresentasikan satu reservasi hotel.
# - Target yang akan diprediksi adalah is_canceled.
# - Dataset berisi kombinasi fitur numerik dan kategorikal.
# - Terdapat informasi mengenai customer, reservasi, kamar, serta pembayaran.
```

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_number	arrival_da
0	Resort Hotel	0	342	2015	July	27	1
1	Resort Hotel	0	737	2015	July	27	1
2	Resort Hotel	0	7	2015	July	27	1
3	Resort Hotel	0	13	2015	July	27	1
4	Resort Hotel	0	14	2015	July	27	1

5 rows × 32 columns

```
# Dataset overview
print(f"Rows : {df.shape[0]:,}")
print(f"Columns : {df.shape[1]:,}")

# Interpretasi
# - 119.390 reservasi (booking)
# - Total ada 32 kolom
# - 1 target (is_canceled)
# - 31 kolom feature (sisanya)
# Ukuran dataset cukup besar untuk membangun model klasifikasi yang stabil.

Rows : 119,390
Columns : 32

# Dataset structure
df.info()

# Interpretasi
# - Tipe data numerik (int64, float64) -> akan dilakukan scaling
# - Tipe data kategorikal (object) -> akan dilakukan encoding
# - Adanya beberapa fitur dengan nilai kosong yang akan dianalisis pada tahap Data Cleaning
# Informasi ini akan digunakan untuk menentukan strategi preprocessing detail pada step berikutnya

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 119390 entries, 0 to 119389
Data columns (total 32 columns):
#   Column                                Non-Null Count  Dtype
---  -
0    hotel                                119390 non-null  object
1    is_canceled                          119390 non-null  int64
2    lead_time                           119390 non-null  int64
3    arrival_date_year                   119390 non-null  int64
4    arrival_date_month                  119390 non-null  object
5    arrival_date_week_number            119390 non-null  int64
6    arrival_date_day_of_month           119390 non-null  int64
7    stays_in_weekend_nights              119390 non-null  int64
8    stays_in_week_nights                119390 non-null  int64
9    adults                              119390 non-null  int64
10   children                            119386 non-null  float64
11   babies                             119390 non-null  int64
12   meal                               119390 non-null  object
13   country                            118902 non-null  object
14   market_segment                     119390 non-null  object
```

```
15 distribution_channel      119390 non-null object
16 is_repeated_guest        119390 non-null int64
17 previous_cancellations    119390 non-null int64
18 previous_bookings_not_canceled 119390 non-null int64
19 reserved_room_type        119390 non-null object
20 assigned_room_type        119390 non-null object
21 booking_changes           119390 non-null int64
22 deposit_type              119390 non-null object
23 agent                     103050 non-null float64
24 company                   6797 non-null float64
25 days_in_waiting_list      119390 non-null int64
26 customer_type             119390 non-null object
27 adr                       119390 non-null float64
28 required_car_parking_spaces 119390 non-null int64
29 total_of_special_requests  119390 non-null int64
30 reservation_status        119390 non-null object
31 reservation_status_date    119390 non-null object
dtypes: float64(4), int64(16), object(12)
memory usage: 29.1+ MB
```

```
# Statistical overview
df.describe().T

# Interpretasi
# - Rentang nilai futur
# - Rata-rata
# - Distribusi awal
# - Potensi nilai ekstrem atau outlier
# Belum dilakukan analisis outlier pada tahap ini, karena akan dibahas pada
  Step 3. Data Cleaning & Preparation.
```

	count	mean	std	min	25%	50%	75%	max
is_canceled	119390.0	0.370416	0.482918	0.00	0.00	0.000	1.0	1.0
lead_time	119390.0	104.011416	106.863097	0.00	18.00	69.000	160.0	737.0
arrival_date_year	119390.0	2016.156554	0.707476	2015.00	2016.00	2016.000	2017.0	2017.0
arrival_date_week_number	119390.0	27.165173	13.605138	1.00	16.00	28.000	38.0	53.0
arrival_date_day_of_month	119390.0	15.798241	8.780829	1.00	8.00	16.000	23.0	31.0
stays_in_weekend_nights	119390.0	0.927599	0.998613	0.00	0.00	1.000	2.0	19.0
stays_in_week_nights	119390.0	2.500302	1.908286	0.00	1.00	2.000	3.0	50.0
adults	119390.0	1.856403	0.579261	0.00	2.00	2.000	2.0	55.0
children	119386.0	0.103890	0.398561	0.00	0.00	0.000	0.0	10.0
babies	119390.0	0.007949	0.097436	0.00	0.00	0.000	0.0	10.0
is_repeated_guest	119390.0	0.031912	0.175767	0.00	0.00	0.000	0.0	1.0
previous_cancellations	119390.0	0.087118	0.844336	0.00	0.00	0.000	0.0	26.0
previous_bookings_not_canceled	119390.0	0.137097	1.497437	0.00	0.00	0.000	0.0	72.0
booking_changes	119390.0	0.221124	0.652306	0.00	0.00	0.000	0.0	21.0
agent	103050.0	86.693382	110.774548	1.00	9.00	14.000	229.0	535.0
company	6797.0	189.266735	131.655015	6.00	62.00	179.000	270.0	543.0
days_in_waiting_list	119390.0	2.321149	17.594721	0.00	0.00	0.000	0.0	391.0
adr	119390.0	101.831122	50.535790	-6.38	69.29	94.575	126.0	5400.0
required_car_parking_spaces	119390.0	0.062518	0.245291	0.00	0.00	0.000	0.0	8.0
total_of_special_requests	119390.0	0.571363	0.792798	0.00	0.00	0.000	1.0	5.0

1.4 Feature Mapping (my personal step)

- Tujuan
- Mengelompokkan fitur berdasarkan fungsi bisnis agar analisis lebih terstruktur
- Reservation & Time Behavior
- Features yang menggambarkan waktu reservasi dan pola durasi menginap.
- Customer & Booking Behavior
- Features yang menggambarkan karakteristik customer dan riwayat perilaku reservasi.

Financial & Operations Behavior

- Features yang berkaitan dengan aspek operasional hotel dan komitmen finansial customer.

Leakage & Technical Features

- Features yang perlu diperiksa lebih lanjut karena berpotensi mengandung informasi outcome (masa depan).

Alasan Pengelompokan

- proses EDA lebih terarah,
- feature engineering lebih mudah dirancang,
- insight bisnis lebih mudah diinterpretasikan,
- proses modeling lebih sistematis.

Gambar struktur terlampir dibawah (AI generated) :



1.5 Step 1 Conclusion

Berdasarkan step Data Understanding:

- Dataset terdiri dari 119.390 data reservasi hotel
- Target prediksi adalah is_canceled
- Dataset memiliki kombinasi fitur numerik dan kategorikal
- Fitur telah dikelompokkan menjadi empat kelompok utama: (hanya untuk pemahaman pribadi)
 - Reservation & Time Behavior
 - Customer & Booking Behavior
 - Financial & Operations Behavior
 - Leakage & Technical Features
- Beberapa fitur berpotensi perlu handle khusus pada next step

Selanjutnya pada step 2 Data Cleaning & Preparation, akan berfokus pada:

- data quality assessment,
- missing value treatment,
- consistency checking,
- leakage handling,
- feature preparation.

2. Data Cleaning & Preparation

2.1 Create Working Dataset

Tujuan

- Membuat salinan dataset mentah yg akan digunakan selama proses cleaning dan preparation
- Langkah pencegahan yg jauh lebih aman saat manipulasi data dan debugging (drop, imputation, feature engineering)

```
df_clean = df.copy()

# Copy raw dataset
# df_clean -> menjadi dataset utama yang digunakan pada seluruh proses
# berikutnya
# df -> dipertahankan sebagai referensi data mentah apabila diperlukan
# proses validasi atau rollback

display(df_clean.head())
# Verify
```

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_number	arrival_da
0	Resort Hotel	0	342	2015	July	27	1
1	Resort Hotel	0	737	2015	July	27	1
2	Resort Hotel	0	7	2015	July	27	1
3	Resort Hotel	0	13	2015	July	27	1
4	Resort Hotel	0	14	2015	July	27	1

5 rows × 32 columns

2.2 Missing Value Audit

Tujuan

- Memeriksa lalu menangani missing value berdasarkan konteks bisnis dan karakteristik features.

```
# Missing value check

missing_values = df_clean.isnull().sum()

missing_table = pd.DataFrame({
    'Missing Value': missing_values,
    'Persentase (%)': round((missing_values / len(df_clean)) * 100, 3),
    'Dtype': df_clean.dtypes
})

missing_table = missing_table[missing_table['Missing Value'] > 0]

display(missing_table.sort_values(by='Missing Value', ascending=False))

# Interpretasi
# - company -> Missing sangat tinggi
# - agent -> Missing tinggi
# - country -> Missing rendah
# - children -> Missing sangat rendah

# Insight
# - Missing pada company kemungkinan menunjukkan booking non-corporate.
# - Missing pada agent kemungkinan menunjukkan direct booking.
# - Missing tidak selalu berarti data rusak.
# - Perlu treatment berbasis konteks bisnis.
```

	Missing Value	Persentase (%)	Dtype
company	112593	94.307	float64
agent	16340	13.686	float64
country	488	0.409	object
children	4	0.003	float64

```
# TREATMENT MISSING VALUE
```

```
# 1. Kolom children (missing 0.003%) -> diisi 0 (tidak punya anak)
df_clean["children"] = df_clean["children"].fillna(0)

# 2. Kolom country (missing 0.4%) -> diisi "Unknown" (tidak diketahui)
df_clean["country"] = df_clean["country"].fillna("Unknown")

# 3. Kolom agent (missing 13.7%) -> diisi 0 (tanpa agen / direct booking)
df_clean["agent"] = df_clean["agent"].fillna(0)

# 4. Kolom company (missing 94.3%) -> drop kolom karena missing ekstrem
df_clean = df_clean.drop(columns=["company"])

# MISSING VALUE VALIDATION

# Cek ulang apakah masih ada missing value di seluruh dataset
missing_after = df_clean.isnull().sum()
missing_after = missing_after[missing_after > 0]

df_clean.isnull().sum()
```

	0
hotel	0
is_canceled	0
lead_time	0
arrival_date_year	0
arrival_date_month	0
arrival_date_week_number	0
arrival_date_day_of_month	0
stays_in_weekend_nights	0
stays_in_week_nights	0
adults	0
children	0
babies	0
meal	0
country	0
market_segment	0
distribution_channel	0
is_repeated_guest	0
previous_cancellations	0
previous_bookings_not_canceled	0
reserved_room_type	0
assigned_room_type	0
booking_changes	0
deposit_type	0
agent	0
days_in_waiting_list	0
customer_type	0
adr	0
required_car_parking_spaces	0
total_of_special_requests	0
reservation_status	0
reservation_status_date	0

dtype: int64

2.3 Duplicated Value Audit

```
# Duplicated data check

duplicate_count = df_clean.duplicated().sum()

print(f"Duplicate Rows : {duplicate_count}")
```

```
print(f"Duplicate Percentage : {duplicate_count/len(df_clean)*100:.3f}%")

# Interpretasi

# Karena dataset tidak memiliki (primary key - angka unik yang membedakan
# setiap data reservasi) :
# - booking_id
# - reservation_id
# - customer_id
# maka duplicate belum tentu salah.

# Bisa saja:
# - reservasi berbeda, namun karakteristik booking identik.
# Maka :
# - Duplicate akan dipertahankan, sampai ditemukan alasan kuat untuk
# menghapusnya.

Duplicate Rows : 32001
Duplicate Percentage : 26.804%
```

2.4 Data Consistency Audit

Tujuan

- Mendeteksi data yang tidak logis atau berpotensi mengganggu analisis

2.4.1 Negative & Outlier ADR

Alasan

- Harga average kamar tidak mungkin bernilai negatif.

```
# Check negative ADR
```

```
negative_adr = df_clean[
    df_clean["adr"] < 0
]
```


```
negative_adr
```

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_number	arrival_date_week_number
14969	Resort Hotel	0	195	2017	March	10	5

1 rows × 31 columns

```
# Check outliers in ADR
plt.figure(figsize=(8,2))
sns.boxplot(x=df['adr'], color='gold')
plt.title('Outliers Detections in ADR')
plt.show()
```

```
adr_outlier = df_clean[df_clean["adr"] > 5000]
display(adr_outlier.sample())
```



	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_number	arrival_date_week_number
48515	City Hotel	1	35	2016	March	13	25

1 rows × 31 columns

```
# Clean the ADR (ternyata ada 1 rows yg mengandung ADR negatif dan ada 1 rows
  outlier bernilai 5400)
```

```
df_clean = df_clean[
    (df_clean["adr"] > 0) & (df_clean["adr"] < 5000)
]
```

```
# Df_clean validation (Negative ADR and Outlier Removed)
```

```
df_clean[
    (df_clean["adr"] < 0) | (df_clean["adr"] > 5000)
]
```

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_number	arrival_date
--	-------	-------------	-----------	-------------------	--------------------	--------------------------	--------------

0 rows × 31 columns

2.4.2 Zero Guest

Alasan

- Reservasi tanpa tamu tidak valid secara bisnis.

```
# Zero Guest Check
```

```
zero_guest = df_clean[
    (df_clean["adults"] == 0) &
    (df_clean["children"] == 0) &
    (df_clean["babies"] == 0)
]
```

zero_guest

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_number	arrival_date
31765	Resort Hotel	0	31	2016	December	53	27
47444	City Hotel	0	48	2016	February	9	21
50701	City Hotel	0	122	2016	May	19	5
50702	City Hotel	0	122	2016	May	19	5
55809	City Hotel	0	256	2016	August	35	21
78586	City Hotel	0	0	2015	November	49	30
85931	City Hotel	0	9	2016	March	12	16
88439	City Hotel	0	52	2016	April	18	30
92814	City Hotel	0	108	2016	July	28	5
92962	City Hotel	0	55	2017	March	10	5
94769	City Hotel	0	4	2016	August	32	5
95544	City Hotel	0	88	2016	August	34	16
96648	City Hotel	0	36	2016	August	35	27
98492	City Hotel	0	1	2016	September	38	17
101399	City Hotel	0	57	2016	November	46	9
101401	City Hotel	0	74	2016	November	46	7
101794	City Hotel	0	140	2016	September	39	22
101957	City Hotel	0	37	2016	November	47	17

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_number	arrival_date
102008	City Hotel	0	1	2016	November	47	18
102185	City Hotel	0	19	2016	November	48	26
103714	City Hotel	0	255	2016	December	53	27
104145	City Hotel	0	177	2016	December	53	30
104516	City Hotel	0	125	2017	January	1	1
106562	City Hotel	0	1	2017	February	7	12
106833	City Hotel	0	50	2017	March	9	1
107594	City Hotel	0	0	2017	March	9	4
111406	City Hotel	0	33	2017	May	19	9
114583	City Hotel	0	26	2017	June	25	19
115029	City Hotel	0	107	2017	June	26	27
116251	City Hotel	0	44	2017	July	28	15
116534	City Hotel	0	2	2017	July	28	15

31 rows × 31 columns

Zero Guest Check (ternyata ada 180 rows dimana guest kategori 0)

```
df_clean = df_clean[
    ~(
        (df_clean["adults"] == 0) &
        (df_clean["children"] == 0) &
        (df_clean["babies"] == 0)
    )
]

# Df_clean validation (Zero Guest Removed)
df_clean[
    (df_clean["adults"] == 0) &
    (df_clean["children"] == 0) &
    (df_clean["babies"] == 0)
]
```

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_number	arrival_date
--	-------	-------------	-----------	-------------------	--------------------	--------------------------	--------------

0 rows × 31 columns

2.4.3 Consistency Summary

Dataset telah melalui pemeriksaan dasar terhadap nilai yang tidak logis

- Negative & Outlier ADR dihapus
- Zero Guest dihapus

Validation

```
print(f"Rows    : {df_clean.shape[0]:,}")
print(f"Columns  : {df_clean.shape[1]:,}")
```

```
Rows      : 117,398
Columns   : 31
```

2.5 Leakage Handling

Tujuan

- Menghapus fitur yang mengandung informasi masa depan dan dapat menyebabkan data leakage.

Leakage Verification

```
pd.crosstab(
    df_clean["reservation_status"],
    df_clean["is_canceled"]
)

# Interpretasi
# status canceled & no-show sudah pasti is_canceled(1) ->
    tidak menginap di hotel / cancel -> tidak
    berpengaruh ke is_canceled
# status check-out sudah pasti is_canceled(0) ->
    menginap di hotel -> tidak
    berpengaruh ke is_canceled
# karena reservation_status adalah leakage, maka reservation_status_date juga
    tidak diperlukan (hanya berisi tanggal status) -> tidak
    berpengaruh ke is_canceled
```

is_canceled	0	1
reservation_status		
Canceled	0	42829
Check-Out	73388	0
No-Show	0	1181

Drop Leakage Features

```
df_clean.drop(
    columns=[
        "reservation_status",
        "reservation_status_date"
    ],
    inplace=True
)

# Validation column leakage sudah terhapus
df_clean.columns.tolist()

['hotel',
 'is_canceled',
 'lead_time',
 'arrival_date_year',
 'arrival_date_month',
 'arrival_date_week_number',
 'arrival_date_day_of_month',
 'stays_in_weekend_nights',
 'stays_in_week_nights',
 'adults',
 'children',
 'babies',
 'meal',
 'country',
 'market_segment',
 'distribution_channel',
 'is_repeated_guest',
 'previous_cancellations',
 'previous_bookings_not_canceled',
 'reserved_room_type',
 'assigned_room_type',
 'booking_changes',
 'deposit_type',
 'agent',
 'days_in_waiting_list',
 'customer_type',
 'adr',
 'required_car_parking_spaces',
 'total_of_special_requests']
```

2.6 Feature Preparation

Tujuan

Mempersiapkan feature yang:

- masih aman dibuat sebelum EDA,
- tidak menyebabkan leakage,
- membantu eksplorasi data,
- berpotensi berguna saat modeling.

Tahap ini belum Feature Engineering penuh, hanya membuat feature dasar yang hampir pasti berguna.

2.6.1 Total Stay

- Merepresentasikan total durasi menginap customer.

```
# Create Total Stay
df_clean["total_stay"] = (
    df_clean["stays_in_weekend_nights"] +
    df_clean["stays_in_week_nights"]
)

# Validation
df_clean[
    [
        "stays_in_weekend_nights",
        "stays_in_week_nights",
        "total_stay"
    ]
].head()
```

	stays_in_weekend_nights	stays_in_week_nights	total_stay
2	0	1	1
3	0	1	1
4	0	2	2
5	0	2	2
6	0	2	2

2.6.2 Total Guests

- Menggambarkan ukuran kelompok reservasi.

```
# Create Total Guests

df_clean["total_guests"] = (
    df_clean["adults"] +
    df_clean["children"] +
    df_clean["babies"]
)

df_clean[
    [
        "adults",
        "children",
        "babies",
        "total_guests"
    ]
].sample(5)
```

	adults	children	babies	total_guests
116722	1	0.0	0	1.0
57570	2	0.0	0	2.0
117454	2	0.0	0	2.0
58057	2	0.0	0	2.0
93657	1	0.0	0	1.0

2.6.3 Feature Preparation Review

- 2 feature baru

```
# New features statistic overview check
```

```
new_features = [
    "total_stay",
    "total_guests"
]

df_clean[new_features].describe().T
```

	count	mean	std	min	25%	50%	75%	max
total_stay	117398.0	3.456498	2.529264	1.0	2.0	3.0	4.0	69.0
total_guests	117398.0	1.973526	0.646541	1.0	2.0	2.0	2.0	12.0

2.7 Clean Dataset Summary

```
# Check cleaned dataset (df_clean)
```

```
df_clean.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 117398 entries, 2 to 119389
Data columns (total 31 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   hotel                                117398 non-null  object
1   is_canceled                          117398 non-null  int64
2   lead_time                           117398 non-null  int64
3   arrival_date_year                   117398 non-null  int64
4   arrival_date_month                 117398 non-null  object
5   arrival_date_week_number           117398 non-null  int64
6   arrival_date_day_of_month          117398 non-null  int64
7   stays_in_weekend_nights            117398 non-null  int64
8   stays_in_week_nights               117398 non-null  int64
9   adults                              117398 non-null  int64
10  children                            117398 non-null  float64
11  babies                             117398 non-null  int64
12  meal                                117398 non-null  object
13  country                             117398 non-null  object
14  market_segment                     117398 non-null  object
15  distribution_channel                117398 non-null  object
16  is_repeated_guest                  117398 non-null  int64
17  previous_cancellations              117398 non-null  int64
18  previous_bookings_not_canceled      117398 non-null  int64
19  reserved_room_type                 117398 non-null  object
20  assigned_room_type                 117398 non-null  object
21  booking_changes                     117398 non-null  int64
22  deposit_type                       117398 non-null  object
23  agent                              117398 non-null  float64
24  days_in_waiting_list               117398 non-null  int64
25  customer_type                      117398 non-null  object
26  adr                                117398 non-null  float64
27  required_car_parking_spaces        117398 non-null  int64
28  total_of_special_requests           117398 non-null  int64
29  total_stay                         117398 non-null  int64
30  total_guests                       117398 non-null  float64
dtypes: float64(4), int64(17), object(10)
memory usage: 28.7+ MB
```

Berdasarkan step Data Cleaning & Preparation:

- Membuat copy dataset untuk di manipulasi
- Memanipulasi missing value, duplicate value, dan logika anomali dalam dataset
- Menghapus column leakage
- Feature baru bisa di elaborasi lebih dalam lagi

Sekarang dataset sudah:

- bersih,
- bebas leakage,
- memiliki feature dasar tambahan,
- siap untuk analisis bisnis.

Selanjutnya pada Step 3 (EDA) akan fokus ke goals utama penilaian bootcamp:

- Analisis lead_time terhadap is_canceled
- Analisis deposit_type terhadap is_canceled
- Menemukan pola cancellation
- Menentukan feature paling berpengaruh untuk model $F1 \geq 82\%$ tanpa kembali lagi ke tahap cleaning.

3. Exploratory Data Analysis (EDA)

```
import matplotlib.patches as mpatches
import warnings; warnings.filterwarnings('ignore')

# — Global Style
plt.rcParams.update({
    'figure.facecolor': '#FAFAFA', 'axes.facecolor': '#FAFAFA',
    'axes.edgecolor': '#CCCCCC', 'axes.spines.top': False,
    'axes.spines.right': False,
    'axes.grid': True, 'grid.color': '#EEEEEE', 'grid.linestyle': '-',
    'grid.alpha': 0.8,
    'font.family': 'sans-serif', 'font.size': 11,
    'axes.titlesize': 13, 'axes.titleweight': 'bold',
    'axes.labelsize': 11, 'xtick.labelsize': 10, 'ytick.labelsize': 10,
})

# — Semantic Palette
C_SAFE, C_MID, C_RISK = '#2E86AB', '#F4A261', '#E84855'

RISK_LEGEND = [mpatches.Patch(color=C_SAFE, label='Low (<25%)'),
                mpatches.Patch(color=C_MID, label='Medium (25-45%)'),
                mpatches.Patch(color=C_RISK, label='High (>45%)')]

def risk_color(rate):
    return C_SAFE if rate < 25 else (C_MID if rate < 45 else C_RISK)

def annotate_bars(ax, fmt='{:.1f}%', offset=0.8, fontsize=10):
    for bar in ax.patches:
        h = bar.get_height()
        if h > 0:
            ax.text(bar.get_x() + bar.get_width()/2, h + offset,
                    fmt.format(h), ha='center', va='bottom',
                    fontsize=fontsize, fontweight='bold', color='#333')

def add_risk_legend(ax, loc='upper left'):
    ax.legend(handles=RISK_LEGEND, loc=loc, framealpha=0.9, fontsize=9,
              title='Risk Level', title_fontsize=9)

sns.set_theme(style="whitegrid")

print('✅ Style & helpers loaded.')

✅ Style & helpers loaded.
```

3.1 Cancellation Overview

Tujuan

Memahami proporsi booking yang dibatalkan dan mengukur tingkat keparahan permasalahan cancellation pada hotel.

Hipotesis

Jika tingkat cancellation cukup tinggi, maka diperlukan model prediksi untuk membantu mitigasi risiko operasional.

— FIGURE 1 · Cancellation Overview

```
cancel_pct = (df_clean['is_canceled'].value_counts(normalize=True)
              .mul(100).round(2).rename({0: 'Not Cancelled', 1: 'Cancelled'}))
counts = df_clean['is_canceled'].value_counts().rename({0: 'Not
              Cancelled', 1: 'Cancelled'})

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 4.5))
fig.suptitle('3.1 Cancellation Overview', fontsize=15, fontweight='bold')

# Bar
bars = ax1.bar(counts.index, counts.values, color=[C_SAFE, C_RISK],
               width=0.5, edgecolor='white')
for bar, val in zip(bars, counts.values):
    ax1.text(bar.get_x()+bar.get_width()/2, bar.get_height()+500,
             f'{val:,.1f}', ha='center', fontsize=11, fontweight='semibold',
             color='#333')
ax1.set_title('Booking Count by Status')
ax1.set_ylabel('Number of Bookings')
```


```

ax1.set_xticks([0,1]); ax1.set_xticklabels(['Not Cancelled\n(0)',
                                             'Cancelled\n(1)'])
ax1.yaxis.set_major_formatter(plt.FuncFormatter(lambda x, _:
                                                  f'{x/1000:.0f}K'))

# Pie
wedges, texts, autotexts = ax2.pie(
    cancel_pct.values, labels=cancel_pct.index, colors=[C_SAFE, C_RISK],
    autopct='%1.1f%%', startangle=90, wedgeprops=
        {'edgecolor': 'white', 'linewidth': 2})
for at in autotexts: at.set(fontsize=12, fontweight='bold', color='white')
ax2.set_title('Cancellation Share')

plt.tight_layout()
plt.savefig('fig1_cancellation_overview.png', dpi=150, bbox_inches='tight')
plt.show()
print(cancel_pct.to_frame('proportion %'))

```



```

proportion %
is_canceled
Not Cancelled    62.51
Cancelled        37.49

```

Observasi

Sebanyak 37.49% booking dibatalkan, sedangkan 62.51% berhasil terealisasi. Proporsi ini menunjukkan bahwa cancellation merupakan kejadian yang cukup sering terjadi.

Insight Bisnis

Hampir 4 dari 10 reservasi tidak berujung pada check-in sehingga berpotensi menyebabkan kehilangan pendapatan dan ketidakpastian okupansi hotel.

Implikasi terhadap Modeling

Target layak digunakan untuk binary classification dan cukup representatif untuk membangun model prediksi cancellation.

3.2 Lead Time Analysis

Tujuan

Menganalisis hubungan antara jarak waktu pemesanan dengan kemungkinan pembatalan reservasi.

Hipotesis

Semakin jauh waktu booking dari tanggal kedatangan, semakin tinggi risiko cancellation.

— FIGURE 2 • Lead Time Risk Curve

```

bins = [0, 30, 90, 180, 365, 800]
labels = ['0-30', '31-90', '91-180', '181-365', '>365']

df_clean['lead_time_bucket'] = pd.cut(df_clean['lead_time'], bins=bins,
                                       labels=labels)

lead_rate = (
    df_clean.groupby('lead_time_bucket', observed=True)['is_canceled']
    .mean().mul(100).round(2)
)

fig, ax = plt.subplots(figsize=(9, 5))
colors = [risk_color(v) for v in lead_rate.values]
bars = ax.bar(lead_rate.index, lead_rate.values, color=colors, width=0.55,
              edgecolor='white')


```

```
# trend line
x = np.arange(len(lead_rate))
ax.plot(x, lead_rate.values, color='#333', linewidth=1.8, marker='o',
        markersize=6, zorder=5, linestyle='--', alpha=0.6)

annotate_bars(ax, offset=0.5)
ax.set_title('3.2 Lead Time → Cancellation Risk')
ax.set_xlabel('Lead Time Bucket (Days Before Arrival)')
ax.set_ylabel('Cancellation Rate (%)')
ax.set_ylim(0, lead_rate.max() * 1.18)

patches = [mpatches.Patch(color=C_SAFE, label='Low risk (<25%)'),
            mpatches.Patch(color=C_MID, label='Medium risk (25-45%)'),
            mpatches.Patch(color=C_RISK, label='High risk (>45%)')]
ax.legend(handles=patches, loc='upper left', framealpha=0.9, fontsize=9)

plt.tight_layout()
plt.savefig('fig2_lead_time.png', dpi=150, bbox_inches='tight')
plt.show()
print(lead_rate.to_frame('cancellation_rate %'))
```



lead_time_bucket	cancellation_rate %
0-30	21.17
31-90	37.93
91-180	44.87
181-365	55.63
>365	67.98

Observasi

Cancellation rate meningkat secara konsisten dari 21.17% (0-30 hari) menjadi 67.98% (>365 hari). Pola ini menunjukkan hubungan positif yang sangat kuat antara lead time dan cancellation.

Insight Bisnis

Customer yang memesan jauh hari memiliki tingkat ketidakpastian lebih tinggi sehingga lebih rentan mengubah atau membatalkan rencana perjalanan.

Implikasi terhadap Modeling

lead_time merupakan salah satu kandidat feature terkuat dan dapat dikembangkan menjadi lead_time_bucket untuk segmentasi risiko.

3.3 Deposit Type Analysis

Tujuan

Menalisis pengaruh jenis deposit terhadap tingkat cancellation.

Hipotesis

Semakin besar komitmen finansial pelanggan, semakin rendah kemungkinan booking dibatalkan.

— FIGURE 3 • Deposit Commitment Analysis

```
dep_rate = (pd.crosstab(df_clean['deposit_type'], df_clean['is_canceled'],
                        normalize='index').mul(100).round(2).sort_values(1))
```

```

fig, ax = plt.subplots(figsize=(8, 5))
bars = ax.bar(dep_rate.index, dep_rate[1].values,
              color=[risk_color(v) for v in dep_rate[1].values],
              width=0.45, edgecolor='white')


# Annotate % on top of each bar
annotate_bars(ax, offset=0.5)

# Insight Label - placed above the Non Refund bar annotation
nr_val = dep_rate.loc['Non Refund', 1]
nr_x = list(dep_rate.index).index('Non Refund')
ax.text(nr_x, nr_val + 10, '⚠ Nearly all cancel!',
       ha='center', va='bottom', fontsize=10.5, color=C_RISK,
       bbox=dict(boxstyle='round,pad=0.3', facecolor='#FFF0F0',
                 edgecolor=C_RISK, alpha=0.9))

ax.set_title('3.3 Deposit Type → Cancellation Risk')
ax.set_xlabel('Deposit Type')
ax.set_ylabel('Cancellation Rate (%)')
ax.set_ylim(0, dep_rate[1].max() * 1.25)
add_risk_legend(ax, loc='upper left')

plt.tight_layout()
plt.savefig('fig3_deposit_type.png', dpi=150, bbox_inches='tight')
plt.show()
print(dep_rate)

```



```

is_canceled    0    1
deposit_type
Refundable     77.78  22.22
No Deposit     71.28  28.72
Non Refund      0.64  99.36

```

Observasi

Tingkat cancellation berbeda secara signifikan antar jenis deposit.

Kategori Non Refund menunjukkan cancellation rate tertinggi sebesar 99.4%, jauh di atas kategori No Deposit (28.7%) maupun Refundable (22.2%).

Insight Bisnis

Hasil ini terlihat bertentangan dengan asumsi umum bahwa kebijakan non-refundable dapat menurunkan pembatalan.

Temuan ini mengindikasikan bahwa pada dataset ini, jenis deposit kemungkinan digunakan sebagai mekanisme pengelompokan reservasi berisiko tinggi, bukan sebagai faktor yang secara langsung menyebabkan pembatalan.

Dengan kata lain, Non Refund lebih berperan sebagai indikator risiko daripada alat pencegah cancellation.

Implikasi terhadap Modeling

Variabel deposit_type memiliki kemampuan diskriminatif yang sangat tinggi dalam membedakan reservasi yang berisiko dibatalkan dan tidak dibatalkan.

Oleh karena itu, feature ini perlu dipertahankan dalam proses pemodelan karena mengandung informasi prediktif yang sangat kuat terhadap target is_canceled.

3.4 Customer Risk Factors

Tujuan

Mengidentifikasi karakteristik pelanggan yang berkaitan dengan risiko cancellation.

Hipotesis

Pelanggan loyal dan memiliki histori yang baik cenderung lebih jarang membatalkan reservasi.

— FIGURE 4 · Customer Risk Dashboard —


```
fig, axes = plt.subplots(1, 3, figsize=(16, 5))
fig.suptitle('3.4 Customer Risk Factors', fontsize=15, fontweight='bold')

# — Panel A: Repeated Guest —
rg = (
    pd.crosstab(df_clean['is_repeated_guest'], df_clean['is_canceled'],
               normalize='index')
    .mul(100)[1]
    .rename({0: 'New Guest', 1: 'Repeat Guest'})
)
colors_rg = [risk_color(v) for v in rg.values]
axes[0].bar(rg.index, rg.values, color=colors_rg, width=0.4,
            edgecolor='white')
annotate_bars(axes[0], offset=0.4)
axes[0].set_title('Repeat vs New Guest')
axes[0].set_ylabel('Cancellation Rate (%)')
axes[0].set_ylim(0, rg.max() * 1.2)

# — Panel B: Previous Cancellations —
prev_cancel_map = {
    0: '0',
    *(i: '1' for i in [1]),
    *(i: '2-10' for i in range(2, 11)),
    *(i: '>10' for i in range(11, 100))
}
df_clean['prev_cancel_grp'] = df_clean['previous_cancellations'].map(
    lambda x: '>10' if x > 10 else ('2-10' if x >= 2 else str(x))
)
pc_order = ['0', '1', '2-10', '>10']
pc_rate = (
    df_clean.groupby('prev_cancel_grp')['is_canceled']
    .mean().mul(100).reindex(pc_order)
)
colors_pc = [risk_color(v) for v in pc_rate.values]
axes[1].bar(pc_rate.index, pc_rate.values, color=colors_pc, width=0.5,
            edgecolor='white')
annotate_bars(axes[1], offset=0.5)
axes[1].set_title('Previous Cancellation History')
axes[1].set_xlabel('Previous Cancellations')
axes[1].set_ylabel('Cancellation Rate (%)')
axes[1].set_ylim(0, pc_rate.max() * 1.2)

# — Panel C: Special Requests —
sr_rate = (
    df_clean.groupby('total_of_special_requests')['is_canceled']
    .mean().mul(100).head(6)
)
colors_sr = [risk_color(v) for v in sr_rate.values]
axes[2].bar(sr_rate.index.astype(str), sr_rate.values, color=colors_sr,
            width=0.5, edgecolor='white')
annotate_bars(axes[2], offset=0.4)
axes[2].set_title('Special Requests → Engagement')
axes[2].set_xlabel('Number of Special Requests')
axes[2].set_ylabel('Cancellation Rate (%)')
axes[2].set_ylim(0, sr_rate.max() * 1.2)

plt.tight_layout()
plt.savefig('fig4_customer_risk.png', dpi=150, bbox_inches='tight')
plt.show()
```



Observasi

Repeated guest memiliki cancellation lebih rendah, sedangkan pelanggan dengan riwayat cancellation sebelumnya memiliki risiko pembatalan yang jauh lebih tinggi. Selain itu, semakin banyak special request yang diajukan, semakin rendah tingkat cancellation.

Insight Bisnis

Perilaku historis pelanggan merupakan indikator penting untuk mengukur tingkat kepercayaan dan komitmen terhadap reservasi.

Implikasi terhadap Modeling

s_repeated_guest, previous_cancellations, dan total_of_special_requests layak dipertahankan sebagai feature prediktif.

3.5 Booking Source Dashboard

Tujuan

Menganalisis pengaruh sumber reservasi terhadap tingkat cancellation.

Hipotesis

Setiap market segment dan distribution channel memiliki karakteristik risiko yang berbeda

— FIGURE 5 · Booking Source Dashboard


```
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 5.5))
fig.suptitle('3.5 Booking Source → Cancellation Risk', fontsize=15,
             fontweight='bold')

# — Market Segment (horizontal, sorted) —
ms_rate = (
    pd.crosstab(df_clean['market_segment'], df_clean['is_canceled'],
               normalize='index')
    .mul(100)[1].sort_values()
)
colors_ms = [risk_color(v) for v in ms_rate.values]
bars = ax1.barh(ms_rate.index, ms_rate.values, color=colors_ms, height=0.55,
               edgecolor='white')
for bar, val in zip(bars, ms_rate.values):
    ax1.text(val + 0.5, bar.get_y() + bar.get_height()/2,
             f'{val:.1f}%', va='center', fontsize=10, fontweight='bold',
             color='#333')
ax1.set_title('By Market Segment')
ax1.set_xlabel('Cancellation Rate (%)')
ax1.set_xlim(0, ms_rate.max() * 1.18)
ax1.axvline(ms_rate.mean(), color='#555', linestyle='--', linewidth=1.2,
            alpha=0.7)
ax1.text(ms_rate.mean() + 0.5, 0, f'avg {ms_rate.mean():.1f}%', fontsize=9,
        color='#555')

# — Distribution Channel —
dc_rate = (
    pd.crosstab(df_clean['distribution_channel'], df_clean['is_canceled'],
               normalize='index')
    .mul(100)[1].sort_values()
)
colors_dc = [risk_color(v) for v in dc_rate.values]
bars2 = ax2.barh(dc_rate.index, dc_rate.values, color=colors_dc, height=0.5,
                edgecolor='white')
for bar, val in zip(bars2, dc_rate.values):
    ax2.text(val + 0.5, bar.get_y() + bar.get_height()/2,
             f'{val:.1f}%', va='center', fontsize=10, fontweight='bold',
             color='#333')
ax2.set_title('By Distribution Channel')
ax2.set_xlabel('Cancellation Rate (%)')
```

```
ax2.set_xlim(0, dc_rate.max() * 1.18)
ax2.axvline(dc_rate.mean(), color='#555', linestyle='--', linewidth=1.2,
            alpha=0.7)
ax2.text(dc_rate.mean() + 0.5, 0, f'avg {dc_rate.mean():.1f}%', fontsize=9,
         color='#555')

plt.tight_layout()
plt.savefig('fig5_booking_source.png', dpi=150, bbox_inches='tight')
plt.show()
```



Observasi

Terdapat perbedaan cancellation rate yang cukup besar antar market segment maupun distribution channel.

Insight Bisnis

Risiko cancellation tidak hanya dipengaruhi oleh pelanggan, tetapi juga asal kanal reservasi yang digunakan.

Implikasi terhadap Modeling

market_segment dan distribution_channel perlu dipertahankan karena mengandung informasi perilaku booking yang relevan.

3.6 Seasonal Risk Analysis

Tujuan

Menguji apakah periode kedatangan tertentu memiliki tingkat cancellation yang berbeda.

Hipotesis

Musim liburan dan periode ramai wisata memiliki tingkat cancellation yang lebih tinggi.

— FIGURE 6 • Seasonal Risk Analysis

```
month_order = ['January', 'February', 'March', 'April', 'May', 'June',
               'July', 'August', 'September', 'October', 'November', 'December']

month_rate = (
    pd.crosstab(df_clean['arrival_date_month'], df_clean['is_canceled'],
               normalize='index')
    .mul(100)[1]
    .reindex(month_order)
)

fig, ax = plt.subplots(figsize=(13, 5))
colors = [risk_color(v) for v in month_rate.values]
x = np.arange(len(month_order))

bars = ax.bar(x, month_rate.values, color=colors, width=0.6,
             edgecolor='white')

# Line overlay
ax.plot(x, month_rate.values, color='#333', linewidth=2, marker='o',
       markersize=5.5, zorder=5, linestyle='-', alpha=0.7)

# value labels
for xi, val in zip(x, month_rate.values):
    ax.text(xi, val + 0.4, f'{val:.1f}%', ha='center', fontsize=8.5,
           fontweight='bold', color='#333')

# avg line
avg = month_rate.mean()
ax.axhline(avg, color='#888', linestyle='--', linewidth=1.4)
```

```


ax.text(11.55, avg + 0.3, f'avg {avg:.1f}%', fontsize=9, color='#666')

ax.set_title('3.6 Seasonal Cancellation Risk by Arrival Month')
ax.set_ylabel('Cancellation Rate (%)')
ax.set_xticks(x)
ax.set_xticklabels([m[:3] for m in month_order])
ax.set_ylim(0, month_rate.max() * 1.2)

patches = [mpatches.Patch(color=C_SAFE, label='Low (<25%)',
                           mpatches.Patch(color=C_MID, label='Medium (25-45%)',
                           mpatches.Patch(color=C_RISK, label='High (>45%)')]
ax.legend(handles=patches, loc='upper right', framealpha=0.9, fontsize=9)

plt.tight_layout()
plt.savefig('fig7_seasonal.png', dpi=150, bbox_inches='tight')
plt.show()
print(month_rate.to_frame('cancel_rate %'))

```



arrival_date_month	cancel_rate %
January	30.948276
February	33.792145
March	32.544624
April	41.124909
May	40.136113
June	41.813812
July	37.820307
August	38.141096
September	39.540052
October	38.512215
November	31.801055
December	35.910339

Observasi

Cancellation rate berfluktuasi sepanjang tahun dan mencapai nilai tertinggi pada periode April–Juni.

Insight Bisnis

Terdapat indikasi pengaruh faktor musiman terhadap perilaku pembatalan reservasi pelanggan.

Implikasi terhadap Modeling

Feature berbasis waktu seperti arrival_date_month dapat dikembangkan menjadi feature musiman (seasonal feature) pada tahap feature engineering.

3.8 EDA Summary

Feature	Indikasi Pengaruh
Lead Time	Sangat Tinggi ★★★★★
Deposit Type	Sangat Tinggi ★★★★★
Previous Cancellations	Tinggi ★★★★★
Repeated Guest	Tinggi ★★★★★
Special Requests	Menengah-Tinggi ★★★★★
Market Segment	Menengah ★★★
Distribution Channel	Menengah ★★★
ADR	Menengah ★★★
Total Stay	Menengah ★★★
Arrival Month	Menengah ★★★

Berdasarkan hasil Exploratory Data Analysis (EDA), beberapa faktor utama yang berhubungan dengan pembatalan reservasi berhasil diidentifikasi:

- Lead Time memiliki hubungan paling kuat dengan cancellation.
- Deposit Type menunjukkan pengaruh signifikan terhadap risiko pembatalan.
- Riwayat cancellation, status repeated guest, dan special request berkontribusi terhadap perilaku pelanggan.
- Market segment dan distribution channel memiliki tingkat risiko yang berbeda.
- Terdapat indikasi pengaruh faktor musiman terhadap cancellation.

Dataset kini telah:

- bersih dan siap digunakan untuk modeling,
- bebas dari leakage feature,
- memiliki kandidat feature penting hasil EDA,
- menghasilkan insight yang mendukung objective bootcamp.

Langkah selanjutnya adalah Step 4 (Modeling & Evaluation), dengan fokus pada:

- Train-Test Split.
- Feature Encoding & Preprocessing.
- Baseline Model Development.
- Model Comparison.
- Evaluasi menggunakan F1-Score.
- Mencapai target F1-Score $\geq 82\%$.

Dengan selesainya tahap EDA, proses dapat dilanjutkan ke tahap machine learning untuk membangun model prediksi hotel booking cancellation yang akurat dan stabil.

4. Modeling & Evaluation

4.1 Feature Selection

Tujuan

- Menentukan feature yang akan digunakan dalam proses machine learning berdasarkan hasil data cleaning, leakage handling, dan temuan dari tahap EDA.

Strategi Pemilihan Feature

Pada tahap EDA ditemukan beberapa feature yang memiliki hubungan kuat terhadap target `is_canceled`. Feature tersebut diprioritaskan untuk digunakan dalam proses modeling.

Feature yang telah teridentifikasi sebagai leakage sebelumnya tidak akan digunakan kembali karena berpotensi memberikan informasi yang tidak tersedia saat prediksi dilakukan.

Feature korelasi cancellation paling kuat

```
core_features = [  
    'lead_time',  
    'deposit_type',  
    'previous_cancellations',
```

```

        'is_repeated_guest',
        'total_of_special_requests'
    ]

    # Feature dipertahankan karena brepotensi meningkatkan performa model
    supporting_features = [
        'hotel',
        'arrival_date_month',
        'stays_in_weekend_nights',
        'stays_in_week_nights',
        'adults',
        'children',
        'babies',
        'country',
        'market_segment',
        'distribution_channel',
        'reserved_room_type',
        'assigned_room_type',
        'booking_changes',
        'agent',
        'customer_type',
        'adr',
        'required_car_parking_spaces',
        'total_stay' # Feature engineering tahap cleaning
        'total_guest' # Feature engineering tahap cleaning
    ]

    # Feature yang sudah dihapus pada tahap cleaning
    excluded_features = [
        'reservation_status',
        'reservation_status_date'
    ]

    df_clean.sample(5)

```

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_number	arriv
94360	City Hotel	0	0	2016	August	32	1
15204	Resort Hotel	1	267	2015	September	39	26
82790	City Hotel	1	68	2016	February	8	17
41722	City Hotel	0	44	2015	August	34	22
101291	City Hotel	0	45	2016	November	46	7

5 rows × 33 columns

```

# FEATURE SELECTION

print(f"Dataset Shape : {df_clean.shape}")

print("\nTarget:")
print("is_canceled")

Dataset Shape : (117398, 33)

Target:
is_canceled

```

Ringkasan

Dataset yang digunakan untuk modeling merupakan hasil akhir dari proses cleaning dan EDA sehingga seluruh feature yang tersisa dianggap valid untuk digunakan dalam proses machine learning.

4.2 ML Dataset Preparation & Train-Test Split

Tujuan

- Mempersiapkan dataset machine learning dengan memisahkan feature dan target serta membagi data menjadi data training dan testing.

Pembagian data dilakukan menggunakan rasio:

- | 80% -> Training Data
- | 20% -> Testing Data
- | stratify=y -> digunakan untuk menjaga proporsi kelas cancellation tetap konsisten pada data train dan test.

Dengan pendekatan ini evaluasi model dapat merepresentasikan kondisi data yang sebenarnya.

```
# FEATURE & TARGET

X = df_clean.drop(columns=['is_canceled'])

y = df_clean['is_canceled']

print("Feature Shape :", X.shape)
print("Target Shape :", y.shape)

Feature Shape : (117398, 32)
Target Shape  : (117398,)

# TRAIN TEST SPLIT

from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.20,
    stratify=y,
    random_state=42
)

print("X Train :", X_train.shape)
print("X Test  :", X_test.shape)

print("y Train :", y_train.shape)
print("y Test  :", y_test.shape)

X Train : (93918, 32)
X Test  : (23480, 32)
y Train : (93918,)
y Test  : (23480,)

# TARGET DISTRIBUTION CHECK

print("Original Distribution")
print(y.value_counts(normalize=True))

print("\nTrain Distribution")
print(y_train.value_counts(normalize=True))

print("\nTest Distribution")
print(y_test.value_counts(normalize=True))

Original Distribution
is_canceled
0    0.625121
1    0.374879
Name: proportion, dtype: float64

Train Distribution
is_canceled
0    0.62512
1    0.37488
Name: proportion, dtype: float64

Test Distribution
is_canceled
0    0.625128
1    0.374872
Name: proportion, dtype: float64
```

Ringkasan

- | Dataset machine learning berhasil dipersiapkan dan dibagi menjadi data training serta testing dengan distribusi target yang tetap terjaga.

Data training akan digunakan untuk membangun model, sedangkan data testing akan digunakan sebagai evaluasi akhir performa model.

4.3 Preprocessing Pipeline

Tujuan

- Menyiapkan transformasi data yang diperlukan sebelum model machine learning dilatih.

Strategi

Dataset terdiri dari kombinasi feature numerik dan kategorikal sehingga diperlukan pendekatan preprocessing yang berbeda untuk masing-masing tipe data.

Feature numerik akan diteruskan tanpa encoding. Feature kategorikal akan diubah menggunakan One Hot Encoding. Seluruh transformasi digabung menggunakan ColumnTransformer.

Pendekatan pipeline digunakan agar proses training dan inference berjalan secara konsisten.

```
# FEATURE TYPE SEPARATION
```

```
categorical_features = X_train.select_dtypes(
    include=['object', 'category']
).columns.tolist()

numerical_features = X_train.select_dtypes(
    exclude=['object', 'category']
).columns.tolist()
```

```
print("Categorical :", len(categorical_features))
print("Numerical   :", len(numerical_features))
```

```
Categorical : 12
Numerical   : 20
```


```
# PREPROCESSOR
```

```
# Disini encoding (OneHotEncoder) tidak dilakukan manual seperti yg diajarkan
# pada bootcamp karena kolom kategorikal ada 12, masa satu2
# Tetapi menggunakan fitur preprocessing dari library scikit yaitu
# OneHotEncoder saja
```

```
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder
```

```
preprocessor = ColumnTransformer(
    transformers=[
        (
            'cat',
            OneHotEncoder(
                handle_unknown='ignore'
            ),
            categorical_features
        )
    ],
    remainder='passthrough'
)
```

preprocessor



Ringkasan

Pipeline preprocessing telah disiapkan untuk menangani seluruh feature kategorikal dan numerik secara otomatis sehingga dapat digunakan kembali pada berbagai algoritma machine learning.

4.4 Baseline Model Development

Tujuan

- Membandingkan beberapa algoritma klasifikasi untuk menentukan model yang paling sesuai dalam memprediksi hotel booking cancellation.

Strategi Pemilihan Model

Dataset hotel booking cancellation memiliki karakteristik:

- kombinasi feature numerik dan kategorikal,
- hubungan non-linear antar variabel,
- jumlah observasi yang besar (>119.000 baris),
- target berupa binary classification,
- objective utama menggunakan F1-Score.

Berdasarkan karakteristik tersebut, dipilih tiga model yang mewakili pendekatan machine learning yang berbeda.

Model	Alasan Pemilihan
Logistic Regression	Baseline linear classifier untuk mengukur performa minimum yang dapat dicapai model sederhana
Random Forest	Ensemble tree-based yang mampu menangkap hubungan non-linear dan interaksi antar feature
XGBoost	Gradient boosting yang dikenal memiliki performa tinggi pada dataset tabular dan sering menjadi benchmark kompetisi machine learning

Dengan membandingkan ketiga model tersebut, dapat diketahui apakah pola cancellation cukup sederhana untuk dipelajari model linear atau membutuhkan model ensemble yang lebih kompleks.

Evaluation Metric

- Metric utama yang digunakan adalah F1-Score.

F1-Score dipilih karena:

- menggabungkan Precision dan Recall,
- lebih representatif dibanding Accuracy pada kasus klasifikasi risiko,
- sesuai dengan objective bootcamp ($F1 \geq 82\%$).

```
# IMPORT MODEL
!pip install xgboost # tidak ada library xgboost dalam google colab (runtime v5e-1 TPU)
```

```
import xgboost as xgb
```

```
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
```

```
from sklearn.pipeline import Pipeline
from sklearn.metrics import (
    f1_score,
    precision_score,
    recall_score,
    accuracy_score
)
```

```
Requirement already satisfied: xgboost in /usr/local/lib/python3.12/dist-packages (3.2.0)
Requirement already satisfied: numpy in /usr/local/lib/python3.12/dist-packages (from xgboost) (2.0.2)
Requirement already satisfied: nvidia-nccl-cu12 in /usr/local/lib/python3.12/dist-packages (from xgboost) (2.30.4)
Requirement already satisfied: scipy in /usr/local/lib/python3.12/dist-packages (from xgboost) (1.16.3)
```

```
# BASELINE MODELS
```

```
models = {
    "Logistic Regression": LogisticRegression(
        max_iter=1000,
        random_state=42
    ),

    "Random Forest": RandomForestClassifier(
```

```

        random_state=42
    ),

    "XGBoost": XGBClassifier(
        random_state=42,
        eval_metric='logloss'
    )
}

# TRAIN & EVALUATE BASELINE

baseline_results = []

for name, model in models.items():

    pipeline = Pipeline([
        ('preprocessor', preprocessor),
        ('model', model)
    ])

    pipeline.fit(X_train, y_train)

    y_pred = pipeline.predict(X_test)

    baseline_results.append({
        'Model': name,
        'Accuracy': accuracy_score(y_test, y_pred),
        'Precision': precision_score(y_test, y_pred),
        'Recall': recall_score(y_test, y_pred),
        'F1 Score': f1_score(y_test, y_pred)
    })

baseline_results = pd.DataFrame(
    baseline_results
)

baseline_results.sort_values(
    by='F1 Score',
    ascending=False
)

```

	Model	Accuracy	Precision	Recall	F1 Score
1	Random Forest	0.896082	0.901743	0.811179	0.854067
2	XGBoost	0.880877	0.859194	0.815951	0.837014
0	Logistic Regression	0.814055	0.815595	0.651216	0.724195

```

# — FIGURE 8 · Baseline Model Comparison
# baseline_results DataFrame already exists from training cell
# C_SAFE, C_MID, C_RISK, add_risk_legend, RISK_LEGEND defined in setup

import matplotlib.ticker as mticker

df_res = baseline_results.sort_values('F1 Score',
    ascending=False).reset_index(drop=True)
metrics = ['Accuracy', 'Precision', 'Recall', 'F1 Score']
METRIC_COLORS = ['#2E86AB', '#3BB273', '#F4A261', '#9B5DE5']

n_models = len(df_res)
n_metrics = len(metrics)
x = np.arange(n_models)
bar_w = 0.18

fig, axes = plt.subplots(1, 2, figsize=(16, 5.5))
fig.suptitle('4. Baseline Model Comparison', fontsize=15, fontweight='bold')

# — Panel A: Grouped Bar — all metrics per model

ax = axes[0]
for i, (metric, color) in enumerate(zip(metrics, METRIC_COLORS)):
    offsets = x + (i - n_metrics/2 + 0.5) * bar_w
    bars = ax.bar(offsets, df_res[metric].values, width=bar_w,
        color=color, edgecolor='white', label=metric, alpha=0.9)
    for bar, val in zip(bars, df_res[metric].values):
        ax.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.003,

```

```

f'{val:.2f}', ha='center', va='bottom', fontsize=7.5,
fontweight='bold', color='#333', rotation=90)

ax.set_title('All Metrics by Model')
ax.set_ylabel('Score')
ax.set_xlabel('Model')
ax.set_xticks(x)
ax.set_xticklabels(df_res['Model'], rotation=20, ha='right')
ax.set_ylim(0, 1.18)
ax.yaxis.set_major_formatter(mticker.PercentFormatter(xmax=1, decimals=0))
ax.axhline(0.5, color='#ccc', lw=1, ls='--')
ax.legend(loc='lower right', fontsize=9, framealpha=0.9, ncol=2)

# — Panel B: Horizontal bar – F1 Score ranking

ax2 = axes[1]
df_sorted = df_res.sort_values('F1 Score') # ascending for hbar (best at
top)

bar_colors = [risk_color((1 - v) * 100) for v in df_sorted['F1
Score'].values]
hbars = ax2.barh(range(len(df_sorted)), df_sorted['F1 Score'].values,
color=bar_colors, height=0.55, edgecolor='white')

for bar, val in zip(hbars, df_sorted['F1 Score'].values):
    ax2.text(val + 0.003, bar.get_y() + bar.get_height()/2,
f'{val:.4f}', va='center', fontsize=10, fontweight='bold',
color='#333')

# Best model callout
best_f1 = df_sorted['F1 Score'].max()
best_idx = df_sorted['F1 Score'].values.tolist().index(best_f1)
ax2.annotate('🏆 Best', xy=(best_f1, best_idx), xytext=(best_f1 - 0.08,
best_idx + 0.5),
fontSize=10, fontweight='bold', color='#3BB273',
arrowprops=dict(arrowstyle='->', color='#3BB273', lw=1.5))

ax2.set_title('F1 Score Ranking')
ax2.set_xlabel('F1 Score')
ax2.set_yticks(range(len(df_sorted)))
ax2.set_yticklabels(df_sorted['Model'])
ax2.set_xlim(0, 1.15)
ax2.xaxis.set_major_formatter(mticker.PercentFormatter(xmax=1, decimals=0))


# Risk Legend repurposed: map to model performance
perf_legend = [
    mpatches.Patch(color=C_SAFE, label='Strong (F1 > 75%)'),
    mpatches.Patch(color=C_MID, label='Moderate (F1 55-75%)'),
    mpatches.Patch(color=C_RISK, label='Weak (F1 < 55%)'),
]
ax2.legend(handles=perf_legend, loc='lower right', framealpha=0.9,
fontSize=9,
title='Performance Level', title_fontsize=9)

plt.tight_layout()
plt.savefig('fig8_baseline_comparison.png', dpi=150, bbox_inches='tight')
plt.show()

print(df_res[['Model'] + metrics].to_string(index=False))

```

4. Baseline Model Comparison



Model	Accuracy	Precision	Recall	F1 Score
Random Forest	0.896082	0.901743	0.811179	0.854067
XGBoost	0.880877	0.859194	0.815951	0.837014
Logistic Regression	0.814055	0.815595	0.651216	0.724195

Hasil Perbandingan Baseline

Model	Accuracy	Precision	Recall	F1 Score
Random Forest	89.61%	90.17%	81.12%	85.41%
XGBoost	88.09%	85.91%	81.60%	83.70%
Logistic Regression	81.41%	81.56%	65.12%	72.42%

Observasi

- Random Forest menghasilkan performa terbaik pada seluruh metrik evaluasi. XGBoost menunjukkan performa yang kompetitif namun masih berada di bawah Random Forest.
- Logistic Regression memiliki performa paling rendah, menunjukkan bahwa pola cancellation tidak sepenuhnya linear.
- Perbedaan performa antara model linear dan tree-based mengindikasikan adanya hubungan non-linear antar feature yang lebih efektif ditangkap oleh model ensemble.

Insight Bisnis

Hasil ini menunjukkan bahwa keputusan pembatalan reservasi tidak dipengaruhi oleh satu faktor secara sederhana, melainkan merupakan kombinasi berbagai karakteristik pelanggan, pola reservasi, dan faktor operasional hotel.

Model berbasis ensemble seperti Random Forest lebih mampu menangkap kompleksitas tersebut dibandingkan model linear.

Berdasarkan F1-Score sebagai metric utama proyek:

Random Forest → Champion Baseline Model = F1-Score = 85.41%

Random Forest dipilih sebagai model final karena menghasilkan performa terbaik pada seluruh metrik evaluasi.

Kesimpulan

Tahap baseline berhasil menunjukkan bahwa Random Forest merupakan kandidat model terbaik untuk memprediksi hotel booking cancellation.

Oleh karena itu proses selanjutnya akan difokuskan pada optimasi Random Forest untuk memperoleh performa yang lebih stabil dan optimal.

4.5 Final Model Evaluation

Tujuan

- Tahap ini bertujuan mengevaluasi performa model terbaik pada data testing yang belum pernah digunakan selama proses pelatihan.

Evaluasi dilakukan menggunakan

- Classification Report Interpretation
- Confusion Matrix Interpretation
- Evaluation Strategy (metrik klasifikasi yaitu Accuracy, Precision, Recall, dan F1-Score)
- Business Insight

Fokus utama proyek ini adalah F1-Score karena metrik tersebut mampu menyeimbangkan kemampuan model dalam mendeteksi cancellation dan meminimalkan kesalahan prediksi.

4.5.1 Classification Report Interpretation

Model menunjukkan performa yang baik pada kedua kelas target.

Untuk kelas cancellation (1), model mencapai Precision sebesar 86% dan Recall sebesar 82%, menunjukkan bahwa sebagian besar reservasi yang berpotensi dibatalkan berhasil teridentifikasi dengan baik.

Perbedaan antara Precision dan Recall menunjukkan bahwa model masih melewatkan sebagian kecil kasus cancellation, namun secara keseluruhan telah menghasilkan F1-Score sebesar 84% pada kelas cancellation.

Nilai ini cukup baik untuk mendukung kebutuhan prediksi risiko pembatalan reservasi.

```
from sklearn.metrics import classification_report

print(
    classification_report(
        y_test,
        y_pred
```

```
)
)
```

	precision	recall	f1-score	support
0	0.89	0.92	0.91	14678
1	0.86	0.82	0.84	8802
accuracy			0.88	23480
macro avg	0.88	0.87	0.87	23480
weighted avg	0.88	0.88	0.88	23480

```
from sklearn.metrics import classification_report
import matplotlib.ticker as mticker

report = classification_report(y_test, y_pred, output_dict=True)
df_rpt = pd.DataFrame(report).T

# Palette – consistent with baseline
M_COLOR = {'precision': '#2E86AB', 'recall': '#F4A261',
            'f1-score': '#9B5DE5', 'support': '#3BB273'}

total_support = int(df_rpt.loc['weighted avg', 'support'])
sup_norm = lambda v: v / total_support # normalise support to 0-1
scale

bar_w = 0.18

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 5.5))
fig.suptitle('5. Classification Report – Best Model', fontsize=15,
             fontweight='bold')

# — Chart 1 · Class 0 & 1 – Precision / Recall / F1 / Support

rows1 = ['0', '1']
xlbls1 = ['Class 0\n(Not Cancelled)', 'Class 1\n(Cancelled)']
cols1 = ['precision', 'recall', 'f1-score', 'support']
x1 = np.arange(len(rows1))

for i, col in enumerate(cols1):
    raw = df_rpt.loc[rows1, col].astype(float).values
    norm = np.where(col == 'support', [sup_norm(v) for v in raw], raw)
    offsets = x1 + (i - len(cols1)/2 + 0.5) * bar_w
    bars = ax1.bar(offsets, norm, width=bar_w,
                   color=M_COLOR[col], edgecolor='white',
                   label=col.capitalize(), alpha=0.9)
    for bar, val in zip(bars, raw):
        lbl = f'{int(val):,}' if col == 'support' else f'{val:.2f}'
        ax1.text(bar.get_x()+bar.get_width()/2, bar.get_height()+0.008,
                 lbl, ha='center', va='bottom', fontsize=8.5,
                 fontweight='bold', color='#333', rotation=90)

ax1.set(title='Per-Class Metrics', ylabel='Score (Support normalised)',
        xticks=x1, xticklabels=xlbls1, ylim=(0, 1.35))
ax1.yaxis.set_major_formatter(mticker.PercentFormatter(xmax=1, decimals=0))
ax1.axhline(0.5, color='ccc', lw=1, ls='--')
ax1.legend(loc='lower right', fontsize=9, framealpha=0.9, ncol=2)

# — Chart 2 · Macro Avg / Weighted Avg (P+R+F1+Sup) | Accuracy (F1+Sup only) —
# Groups: Macro Avg, Weighted Avg → 4 bars each
# Accuracy → 2 bars only (f1-score + support), placed Last, wider

rows_avg = ['macro avg', 'weighted avg']
cols_avg = ['precision', 'recall', 'f1-score', 'support']
x2 = np.arange(len(rows_avg)) # positions 0, 1
x_acc = np.array([2.6]) # accuracy shifted right, gap = 0.6
bar_w_avg = 0.18
bar_w_acc = 0.30 # wider for accuracy

# Draw Macro & Weighted Avg – 4 bars each
for i, col in enumerate(cols_avg):
    raw = df_rpt.loc[rows_avg, col].astype(float).values
    norm = np.where(col == 'support', [sup_norm(v) for v in raw], raw)
    offsets = x2 + (i - len(cols_avg)/2 + 0.5) * bar_w_avg
    bars = ax2.bar(offsets, norm, width=bar_w_avg,
                   color=M_COLOR[col], edgecolor='white', alpha=0.9,
                   label=col.capitalize() if i < len(cols_avg) else '_')
```

```

for bar, val in zip(bars, raw):
    lbl = f'{int(val):,}' if col == 'support' else f'{val:.2f}'
    ax2.text(bar.get_x()+bar.get_width()/2, bar.get_height()+0.008,
             lbl, ha='center', va='bottom', fontsize=8.5,
             fontweight='bold', color='#333', rotation=90)

# Draw Accuracy - F1 + Support only, wider bars, side by side
acc_f1 = float(df_rpt.loc['accuracy', 'f1-score'])
acc_sup = total_support # always full support

for j, (col, raw_val) in enumerate(['f1-score', acc_f1), ('support',
acc_sup)]:
    norm_val = sup_norm(raw_val) if col == 'support' else raw_val
    offset = x_acc + (j - 1) * bar_w_acc
    bar = ax2.bar(offset, norm_val, width=bar_w_acc,
                  color=M_COLOR[col], edgecolor='white', alpha=0.9)
    lbl = f'{int(raw_val):,}' if col == 'support' else f'{raw_val:.2f}'
    ax2.text(offset[0], norm_val + 0.008, lbl,
             ha='center', va='bottom', fontsize=8.5,
             fontweight='bold', color='#333', rotation=90)


# X-axis ticks
ax2.set_xticks(list(x2) + [float(x_acc)])
ax2.set_xticklabels(['Macro Avg', 'Weighted Avg', 'Accuracy'])
ax2.set(title='Summary Averages', ylabel='Score (Support normalised)', ylim=
(0, 1.35))
ax2.yaxis.set_major_formatter(mticker.PercentFormatter(xmax=1, decimals=0))
ax2.axhline(0.5, color='ccc', lw=1, ls='--')

# Divider line between avg groups and accuracy
ax2.axvline(2.1, color='ccc', lw=1.2, ls=':')
ax2.text(2.12, 1.28, 'Accuracy\n(F1 + Support only)', fontsize=8.5,
        color='#666', va='top')

ax2.legend(loc='lower right', fontsize=9, framealpha=0.9, ncol=2)

plt.tight_layout()
plt.savefig('fig10_clf_report.png', dpi=150, bbox_inches='tight')
plt.show()

```



4.5.2 Confusion Matrix Interpretation

Confusion Matrix memberikan gambaran mengenai jumlah prediksi yang benar dan salah pada masing-masing kelas.

Sebagian besar observasi berhasil diklasifikasikan dengan benar baik untuk kelas cancellation maupun non-cancellation.

Jumlah False Positive dan False Negative relatif rendah dibandingkan total observasi, menunjukkan bahwa model memiliki kemampuan prediksi yang stabil.

Dari perspektif bisnis, hasil ini penting karena kesalahan prediksi yang terlalu tinggi dapat menyebabkan keputusan operasional yang kurang optimal, seperti salah memperkirakan tingkat okupansi kamar atau memberikan perlakuan yang tidak sesuai kepada pelanggan.

```
from sklearn.metrics import ConfusionMatrixDisplay
```

```

ConfusionMatrixDisplay.from_predictions(
    y_test,
    y_pred,
    cmap='Blues'
)


```

```

plt.title("Random Forest Confusion Matrix")
plt.show()

```

Confusion Matrix Interpretation
 # - Sebagian besar reservasi berhasil diklasifikasikan dengan benar baik pada kelas cancellation maupun non-cancellation.
 # - Jumlah False Positive dan False Negative relatif rendah dibandingkan total observasi, menunjukkan bahwa model memiliki kemampuan prediksi yang stabil dan dapat digunakan sebagai sistem pendukung keputusan operasional hotel.



4.5.3 Evaluation Strategy

Evaluasi dilakukan menggunakan beberapa metrik klasifikasi:

- Accuracy → proporsi prediksi yang benar secara keseluruhan.
- Precision → kemampuan model mengidentifikasi cancellation secara tepat.
- Recall → kemampuan model menangkap cancellation yang benar-benar terjadi.
- F1-Score → keseimbangan antara Precision dan Recall.

Karena tujuan bisnis utama adalah mengidentifikasi potensi cancellation secara akurat, maka F1-Score digunakan sebagai metric utama.

Hasil Evaluasi Model | Metric | Score | ----- | ----- | Accuracy | 89.61% |
 Precision | 90.17% | Recall | 81.12% | F1-Score | **85.41%** |

Observasi

- Model berhasil mencapai F1-Score sebesar 85.41%, melampaui target bootcamp sebesar 82%.
- Precision yang tinggi menunjukkan sebagian besar prediksi cancellation yang diberikan model memang benar terjadi.
- Recall di atas 80% menunjukkan model mampu menangkap sebagian besar kasus cancellation aktual.
- Keseimbangan antara Precision dan Recall menghasilkan performa yang stabil untuk kebutuhan prediksi bisnis.

4.5.4 Business Insight

- Dari perspektif operasional hotel, model ini mampu mengidentifikasi pelanggan yang berpotensi melakukan pembatalan reservasi dengan tingkat akurasi yang tinggi.

Kemampuan ini dapat dimanfaatkan untuk:

- pemberian reminder otomatis,
- penerapan kebijakan deposit yang lebih tepat,
- pengelolaan inventory kamar,
- strategi overbooking yang lebih terukur.

Kesimpulan

- Model berhasil melampaui target minimum F1-Score sebesar 82% dan menunjukkan kemampuan yang baik dalam memprediksi risiko cancellation.

Oleh karena itu, Random Forest dipilih sebagai model final untuk digunakan dalam analisis dan rekomendasi bisnis pada tahap berikutnya.

4.6 Modeling Summary

Berdasarkan proses machine learning yang telah dilakukan, beberapa kesimpulan utama berhasil diperoleh:

- Random Forest menjadi model dengan performa terbaik dibandingkan Logistic Regression dan XGBoost.
- Model mencapai F1-Score sebesar 85.41%, melampaui target minimum bootcamp sebesar 82%.
- Hasil menunjukkan bahwa pola cancellation bersifat non-linear dan lebih efektif dipelajari oleh model ensemble dibanding model linear.
- Model yang dihasilkan memiliki performa yang cukup stabil untuk digunakan sebagai sistem prediksi risiko pembatalan reservasi.

Ringkasan Hasil Modeling | Komponen | Hasil | | ----- | ----- | | Target | is_canceled | | Task | Binary Classification | | Model Terbaik | Random Forest | | Accuracy | 89.61% | | Precision | 90.17% | | Recall | 81.12% | | F1-Score | **85.41%** | | Target Bootcamp | $\geq 82\%$ | | Status |  Tercapai |

Dengan selesainya tahap modeling, seluruh objective machine learning telah berhasil dicapai.

Tahap berikutnya akan berfokus pada penerjemahan hasil analisis dan hasil model menjadi insight bisnis serta rekomendasi operasional yang dapat membantu hotel mengurangi risiko pembatalan reservasi di masa mendatang.

5. Insight & Conclusion

5.1 Executive Summary

Tujuan

- Menyajikan ringkasan hasil analisis dan pemodelan yang telah dilakukan untuk memahami faktor-faktor yang memengaruhi pembatalan reservasi hotel serta membangun model prediksi cancellation.

Ringkasan Project | Komponen | Hasil | | ----- | ----- | | Total Data | 119,390 reservasi | | Target | is_canceled | | Cancellation Rate | 37.49% | | Jenis Masalah | Binary Classification | | Model Terbaik | Random Forest | | Accuracy | 89.61% | | Precision | 90.17% | | Recall | 81.12% | | F1-Score | 85.41% | | Target Bootcamp | $\geq 82\%$ | | Status |  Tercapai |

Ringkasan Temuan Utama

- Tingkat cancellation mencapai 37.49% dari seluruh reservasi.
- Lead time memiliki hubungan yang sangat kuat terhadap risiko cancellation.
- Tipe deposit menunjukkan pengaruh signifikan terhadap perilaku pembatalan pelanggan.
- Riwayat cancellation sebelumnya menjadi indikator kuat terjadinya cancellation di masa mendatang.
- Repeated guest cenderung memiliki tingkat cancellation yang lebih rendah dibanding pelanggan baru.
- Model Random Forest berhasil memprediksi cancellation dengan performa yang melampaui target bootcamp.

Kesimpulan Singkat

Analisis menunjukkan bahwa pembatalan reservasi tidak terjadi secara acak, melainkan dipengaruhi oleh karakteristik pemesanan, perilaku pelanggan, dan kebijakan reservasi yang diterapkan hotel.

Temuan ini dapat digunakan sebagai dasar dalam merancang strategi mitigasi cancellation yang lebih efektif.

5.2 Root Cause Analysis

Tujuan

- Mengidentifikasi faktor-faktor utama yang berkontribusi terhadap pembatalan reservasi hotel berdasarkan hasil Exploratory Data Analysis (EDA).

1. Lead Time sebagai Faktor Risiko Utama

Analisis menunjukkan korelasi positif yang sangat kuat antara lead time dan tingkat pembatalan. Reservasi dengan lead time singkat (0–30 hari) memiliki tingkat pembatalan rendah (~21.17%), sementara reservasi yang dilakukan lebih dari satu tahun sebelumnya (>365 hari) memiliki risiko pembatalan hingga 67.98%.

Insight:

Lead time merupakan prediktor risiko paling signifikan. Semakin lama jeda waktu, semakin besar ketidakpastian rencana pelanggan.

1. Pengaruh Deposit Type terhadap Komitmen

Terdapat perbedaan perilaku yang mencolok antar jenis deposit. Meskipun secara umum jaminan finansial diharapkan menurunkan pembatalan, data menunjukkan bahwa kategori 'No Deposit' memiliki volume pembatalan yang sangat besar karena rendahnya hambatan finansial bagi pelanggan untuk membatalkan pesanan.

Insight:

Kebijakan deposit yang tepat sangat krusial untuk memitigasi kerugian operasional akibat pembatalan mendadak.

1. Riwayat Pembatalan dan Loyalitas

Pelanggan dengan riwayat 'Previous Cancellations' memiliki probabilitas pembatalan jauh lebih tinggi pada pesanan berikutnya. Sebaliknya, 'Repeated Guest' menunjukkan tingkat loyalitas yang lebih baik dengan rasio pembatalan yang lebih rendah dibandingkan pelanggan baru.

Insight:

Histori perilaku pelanggan adalah indikator kuat untuk prediksi di masa depan. Program loyalitas dapat membantu menurunkan tingkat pembatalan secara keseluruhan.

1. Market Segment dan Distribution Channel

Analisis menunjukkan adanya perbedaan tingkat pembatalan yang cukup signifikan antar sumber reservasi. Segmen Groups (61.7%) dan Online TA (36.9%) memiliki tingkat cancellation yang jauh lebih tinggi dibandingkan Direct Booking (15.4%) maupun Corporate Booking (18.9%).

Pola serupa juga terlihat pada Distribution Channel, dimana TA/TO (41.4%) memiliki risiko pembatalan lebih tinggi dibandingkan channel Direct dan Corporate.

Insight:

Sumber reservasi mencerminkan tingkat komitmen pelanggan yang berbeda. Reservasi melalui perantara seperti OTA dan agen perjalanan cenderung memiliki risiko cancellation lebih tinggi dibandingkan reservasi langsung ke hotel.

1. Pengaruh Musiman (Seasonality)

Analisis berdasarkan bulan kedatangan menunjukkan bahwa tingkat cancellation tidak bersifat konstan sepanjang tahun.

Terdapat beberapa periode dengan tingkat pembatalan yang lebih tinggi dibandingkan rata-rata, yang mengindikasikan adanya pengaruh faktor musiman, pola liburan, maupun perubahan perilaku pelanggan pada periode tertentu.

Insight:

Periode kedatangan merupakan indikator risiko yang penting. Hotel perlu mengantisipasi fluktuasi cancellation pada musim tertentu melalui strategi reservasi dan perencanaan operasional yang lebih adaptif.

Validasi dengan Hasil Modeling

Hasil Feature Importance dari model Random Forest menunjukkan bahwa Deposit Type, Previous Cancellations, dan beberapa indikator perilaku reservasi lainnya merupakan feature yang memiliki kontribusi besar terhadap prediksi cancellation.

Temuan ini selaras dengan hasil EDA sehingga meningkatkan kepercayaan terhadap model yang dibangun.

Faktor Utama yang Mempengaruhi Cancellation

Berdasarkan seluruh hasil EDA, faktor-faktor yang paling berpengaruh terhadap pembatalan reservasi adalah:

- 1. Lead Time
- 2. Deposit Type
- 3. Previous Cancellations & Repeated Guest Status
- 4. Market Segment & Distribution Channel
- 5. Seasonality (Arrival Month / Holiday Period)

Kesimpulan

- Pembatalan reservasi dipengaruhi oleh kombinasi faktor perilaku pelanggan, sumber reservasi, waktu pemesanan, dan kebijakan hotel.
- Dengan memahami faktor-faktor tersebut, hotel dapat melakukan intervensi lebih awal, mengurangi risiko cancellation, serta meningkatkan efektivitas perencanaan operasional dan pendapatan.

5.3 Predictive Model Findings

Tujuan

- Mengevaluasi bagaimana model machine learning dapat dimanfaatkan untuk mendukung pengambilan keputusan operasional hotel.

Hasil Pemodelan

Dari beberapa algoritma yang diuji, Random Forest menghasilkan performa terbaik dengan:

Metric	Score
Accuracy	89.61%
Precision	90.17%
Recall	81.12%
F1-Score	85.41%

Interpretasi Model

- Performa model menunjukkan bahwa pola cancellation dapat dipelajari dan diprediksi dengan tingkat akurasi yang tinggi.

Dengan F1-Score sebesar 85.41%, model mampu menyeimbangkan kemampuan:

- mendeteksi reservasi yang berpotensi dibatalkan,
- mengurangi kesalahan prediksi terhadap reservasi yang tetap berlangsung.

Nilai Bisnis Model

- Model prediksi cancellation dapat digunakan sebagai sistem peringatan dini (early warning system) bagi hotel.

Sebelum tanggal check-in, hotel dapat mengidentifikasi reservasi yang memiliki risiko cancellation tinggi dan melakukan tindakan pencegahan seperti:

- pengiriman reminder otomatis,
- penawaran ulang reservasi,
- penerapan kebijakan deposit tambahan,
- penyesuaian strategi overbooking.

Manfaat Operasional

Dengan adanya sistem prediksi cancellation, hotel berpotensi memperoleh manfaat berupa:

- peningkatan tingkat okupansi kamar,
 - pengurangan kerugian akibat kamar kosong,
 - pengelolaan inventori kamar yang lebih efisien,
 - pengambilan keputusan yang lebih berbasis data.
- Kesimpulan
- Model Random Forest berhasil mencapai F1-Score sebesar 85.41%, melampaui target bootcamp sebesar 82%. Hasil ini menunjukkan bahwa machine learning dapat dimanfaatkan secara efektif untuk memprediksi risiko pembatalan reservasi dan mendukung strategi operasional hotel yang lebih proaktif.

5.4 Business Recommendations & Dynamic

Cancellation Policy

Tujuan

- Menerjemahkan hasil analisis data dan model machine learning menjadi rekomendasi bisnis yang dapat membantu hotel mengurangi risiko pembatalan reservasi dan meningkatkan efisiensi operasional.

1. Implementasi Kebijakan Pembatalan Berbasis Risiko (Dynamic Policy)

Hotel harus menerapkan kebijakan deposit dan pembatalan yang dinamis berdasarkan profil risiko reservasi yang dihasilkan oleh model:

- **High Risk (Lead Time > 120 hari, No Deposit):** Wajibkan deposit non-refundable atau pembayaran di muka.
- **Medium Risk:** Terapkan batas waktu pembatalan gratis yang lebih ketat (misal: 14 hari sebelum check-in).
- **Low Risk (Repeated Guest):** Berikan fleksibilitas pembatalan sebagai bentuk apresiasi loyalitas.

2. Optimalisasi Engagement melalui Automated Reminder System

Mengingat lead time yang panjang adalah faktor risiko utama, hotel perlu menjaga komunikasi dengan pelanggan melalui sistem pengingat otomatis:

- Kirimkan notifikasi konfirmasi ulang pada H-30, H-14, dan H-7 sebelum tanggal kedatangan.
- Sertakan opsi 'upsell' atau penawaran menarik lainnya dalam pengingat untuk memperkuat minat tamu menginap.

3. Integrasi Model Prediksi ke Property Management System (PMS)

Manfaatkan model Random Forest (F1-Score: 85.41%) sebagai sistem peringatan dini (Early Warning System):

- Tandai reservasi berisiko tinggi secara otomatis dalam sistem agar tim reservasi dapat melakukan tindak lanjut manual (misal: telepon konfirmasi).
- Gunakan hasil prediksi untuk mengatur strategi *overbooking* yang lebih akurat guna meminimalkan kerugian akibat kamar kosong.

Kesimpulan Rekomendasi

Dengan mengintegrasikan model prediksi ke dalam operasional dan menerapkan kebijakan berbasis risiko, hotel dapat secara proaktif menekan tingkat pembatalan dari angka saat ini (37.49%) dan mengoptimalkan tingkat okupansi kamar.

5.5 Project Conclusion

Ringkasan Pencapaian Proyek

Proyek ini berhasil menganalisis faktor-faktor yang memengaruhi pembatalan reservasi hotel dan membangun model machine learning untuk memprediksi risiko cancellation.

Beberapa temuan utama yang diperoleh adalah:

- Lead Time merupakan faktor yang paling berpengaruh terhadap cancellation.
- Deposit Type menunjukkan hubungan yang kuat terhadap tingkat pembatalan reservasi.
- Previous Cancellations dapat digunakan sebagai indikator perilaku pelanggan di masa mendatang.
- Repeated Guest memiliki risiko cancellation yang lebih rendah dibandingkan pelanggan baru.
- Market Segment dan Distribution Channel menunjukkan perbedaan risiko cancellation yang signifikan antar sumber reservasi.
- Terdapat indikasi pengaruh faktor musiman (seasonality) terhadap tingkat cancellation pada periode tertentu.
- Model Random Forest menghasilkan performa terbaik dengan F1-Score sebesar 85.41%.

Objective	Status
Mengidentifikasi pola Lead Time terhadap Cancellation	✓ Tercapai
Menganalisis pengaruh Deposit Type terhadap Cancellation	✓ Tercapai
Menangani Missing Values pada Agent dan Preferensi Kamar	✓ Tercapai
Membangun Model Klasifikasi dengan $F1 \geq 82\%$	✓ Tercapai
Menyusun Dynamic Cancellation Policy	✓ Tercapai

Business Impact & Strategic Value

Hasil analisis menunjukkan bahwa risiko pembatalan reservasi tidak terjadi secara acak, melainkan dipengaruhi oleh pola perilaku pelanggan yang dapat diidentifikasi sejak proses pemesanan berlangsung.

Dengan memanfaatkan faktor-faktor utama seperti Lead Time, Deposit Type, Previous Cancellations, Market Segment, dan Seasonality, hotel dapat mengembangkan pendekatan yang lebih proaktif dalam mengelola reservasi berisiko tinggi.

Potensi manfaat yang dapat diperoleh antara lain:

- Mengurangi kehilangan pendapatan akibat pembatalan mendadak.
- Meningkatkan akurasi perencanaan okupansi hotel.
- Membantu proses revenue management melalui kebijakan reservasi yang lebih adaptif.
- Mendukung pengambilan keputusan berbasis data dalam operasional hotel.
- Memprioritaskan tindakan mitigasi pada reservasi dengan tingkat risiko tinggi.

Kesimpulan Akhir

Hasil analisis menunjukkan bahwa pembatalan reservasi hotel dapat diprediksi menggunakan kombinasi karakteristik pemesanan, perilaku pelanggan, sumber reservasi, serta faktor musiman.

Model Random Forest berhasil mencapai F1-Score sebesar 85.41%, melampaui target bootcamp ($F1 \geq 82\%$) dan menunjukkan kemampuan yang baik dalam mengidentifikasi reservasi berisiko tinggi.

Berdasarkan temuan tersebut, hotel dapat menerapkan kebijakan pembatalan yang lebih adaptif, memanfaatkan sistem prediksi risiko sebagai alat pendukung keputusan, serta mengoptimalkan strategi loyalitas dan manajemen reservasi untuk mengurangi kerugian operasional akibat cancellation.

Secara keseluruhan, proyek ini berhasil memenuhi seluruh objective utama bootcamp sekaligus menghasilkan insight bisnis yang dapat diterapkan untuk meningkatkan efektivitas pengelolaan reservasi hotel.